

### 第3章 線形回帰モデル

回帰の目的は、観測点と対応する目標値からなる訓練データが与えられたとき、新たな $x$ に対する $t$ の値を予測することである。

本章では、回帰モデルの中でも、入力に対して**基底関数**と呼ばれる非線形な関数を適用した値に対して、線形結合を行ったモデルを扱う。

最も簡単な線形回帰モデルは入力変数の線形結合である。

$$y(x, w) = w_0 + w_1 x_1 + \dots + w_p x_p$$

これでは表現力が乏しいため、入力変数に関して非線形な関数の線形結合を考える。



$$\begin{aligned} y(x, w) &= w_0 + \sum_{j=1}^{M-1} w_j \phi_j(x) \\ &= \sum_{j=0}^{M-1} w_j \phi_j(x) \quad (\because \phi_0(x) = 1 \text{ と } w_0) \\ &= w' \phi(x) \end{aligned}$$

例えば、多項式モデルであれば、基底関数は次のようになる。

$$\phi(x) = \begin{pmatrix} 1 \\ x \\ x^2 \\ \vdots \\ x^k \end{pmatrix}$$

(スプライン関数について) 自信はないが、たぶんこうかな、という  
ことだけ記す。


「多項式は入力変数の大域的な関数であるため、入力空間のある領  
域の変化が他の領域に及んでしまう」とは、あるサンプルにおける  
目標変数が変動したら、そのサンプルの $x$ 以外の領域の回帰結果も変  
動することを言っているのだと思う。



基底関数を次のようなスプライン関数とすると、異なる領域に影響を及ぼさ  
なくなる。

$$\phi(x) = \begin{cases} \begin{pmatrix} 1 \\ x \\ x^2 \\ x^3 \\ 0 \\ 0 \\ 0 \\ 0 \end{pmatrix} & (x \leq 0) \\ \begin{pmatrix} 0 \\ 0 \\ 0 \\ 0 \\ 1 \\ x \\ x^2 \\ x^3 \end{pmatrix} & (x \geq 0) \end{cases}$$

## 回帰の結果のイメージ



他にも次のような基底関数がある。

### ガウス基底関数

$$\phi_i(x) = \exp\left\{-\frac{(x-\mu_i)^2}{2s^2}\right\}$$

### シグモイド基底関数

$$\phi_i(x) = \sigma\left(\frac{x-\mu_i}{s}\right) \quad \left(\because \sigma(a) = \frac{1}{1+e^{-a}}\right)$$

### フーリエ基底

ちょっとイメージつかなかった。。基底関数がある単一の周波数に対応するとは??

## 3.1.1 最尤推定と最小二乗法

既に学習した内容については割愛する。誤差にガウスノイズを仮定して、最尤推定によってパラメータ推定を行うと、最小二乗法に一致する。最小二乗法の解は、正規方程式を解くことによって得られる。

$$w_{ML} = (\Phi' \Phi)^{-1} \Phi' t$$

↑ 計画行列

$$\begin{pmatrix} \phi_0(x_1) & \dots & \phi_{m-1}(x_1) \\ \vdots & & \\ \phi_0(x_n) & \dots & \phi_{m-1}(x_n) \end{pmatrix}$$

ここで、

$$\Phi^{\dagger} \equiv (\Phi' \Phi)^{-1} \Phi'$$

を  $M$ - $N$  ペンローズの擬似逆行列 というらしい。

ガウスノイズの精度パラメータ  $\beta$  についても、次の最尤推定量が得られる。

$$\frac{1}{\beta_{ML}} = \frac{1}{N} \sum_{n=1}^N (t_n - w_{ML}' \phi(x_n))^2$$

### 3.1.2 最小二乗法の幾何学

水色の教科書p42あたりの内容と同等のことが書いてある。


軽くおさらいする。

結論から言うと、最小二乗法によるパラメータ推定は、真の目標変数ベクトルを、ある空間に正射影したベクトルを求めることに相当する。

- ・ある空間とは、計画行列の列ベクトルで張られる空間である。
- ・正射影したベクトルは、予測ベクトル  $y (= \Phi w_{ML})$  に相当する。

$$\Phi = (\phi_1, \phi_2, \dots, \phi_m)$$

↓  
N次元ベクトル



右図でいう、 $\sqrt{\|t - y\|_2}$  を最小化したい

というのは、 $y$  が  $t$  の正射影である  
ということと同義である。実際に、

$$y = \Phi w_{ML} = \Phi (\Phi' \Phi)^{-1} \Phi' t$$

こゝが  $\{\phi_i\}$  の張る空間への正射影となる、という。(\*)

(\*) これを示す. (演習 3.2)

$\mathbb{C} - \mathcal{Q}$  が, 行束の  $\varphi_i$  と直交する  $\mathbb{C}$  を示せば良い.

$$\varphi_i'(\mathbb{C} - \mathcal{Q}) = \varphi_i'(\mathbb{I} - \Phi(\Phi'\Phi)'\Phi')\mathbb{C}$$

これを  $m$  行に並べて,

$$\underbrace{\begin{pmatrix} \varphi_1' \\ \varphi_2' \\ \vdots \\ \varphi_m' \end{pmatrix}}_{= \Phi'} (\mathbb{C} - \mathcal{Q}) = \underbrace{\begin{pmatrix} \varphi_1' \\ \varphi_2' \\ \vdots \\ \varphi_m' \end{pmatrix}}_{= \Phi'} (\mathbb{I} - \Phi(\Phi'\Phi)'\Phi')\mathbb{C}$$

$$= (\Phi' - \underbrace{\Phi'\Phi(\Phi'\Phi)'\Phi'}_I)\mathbb{C}$$

$$= (\Phi' - \Phi')\mathbb{C}$$

$$= \mathbf{0}$$

と示せば良い.