

2.5.1

【最小二乗推定量】



→ 詳細は 2.2.1 節にある。

ってなんなの、け？

最小二乗法によって得られる。

母数ベクトル θ の推定量 $\hat{\theta}$

$$[\text{すなわち、} X'X \hat{\theta} = X'y \text{ を満たす}]$$

の総形表示によって表わされる推定量

$$I' \hat{\theta} \quad \text{のこと。}$$

例) 一元配置分散分析で

$$\mu, \alpha, \mu + \alpha,$$

など。

単回帰で。

$$\beta_0, \beta_1, \beta_0 + x\beta_1$$

など。

2.5.1

最小二乗推定量は、次の線形結合だから ...

$$\begin{array}{l}
 l' \\
 \downarrow
 \end{array}
 \left\{ \begin{array}{l}
 X \text{ がフルランク のとき, } l'(X'X)X' \text{ は} \\
 \text{"} \quad \text{ " のとき, 推定可能関数} \\
 \text{である. その定義より 上の線形結合}
 \end{array} \right.$$

2.5.2

とくに射影行列 $I - \Pi_X$ の場合は、固有値は ν_e の 1 と $n - \nu_e$ の 0 から成る。

Π_X は $L(X)$ への射影子で、固有値は

$$\begin{array}{ll}
 1 & \text{が } \text{rank}(\Pi_X) = \text{rank}(X) = q \text{ 個} \\
 0 & \text{が } n - q \text{ 個}
 \end{array}
 \quad (p. 69)$$

$I - \Pi_X$ は $L(X)$ の直交補空間への射影子 となる。
(図 2.3)

$n - \text{rank}(X)$ 個の直交ベクトルから張られる

固有値は、

$$\begin{array}{ll}
 1 & \text{が } n - q = \nu_e \text{ 個} \\
 0 & \text{が } q = n - \nu_e \text{ 個}
 \end{array}$$


2.5.2

式 (4)

$$\begin{aligned}
 S(\hat{\theta}) &= (y - X\hat{\theta})'(y - X\hat{\theta}) \\
 &= ((I - \pi_X)y)'((I - \pi_X)y) \\
 &= y'(I - \pi_X)'(I - \pi_X)y \\
 &= y' \left(\underbrace{\sum l_i l_i'}_{\text{行列の和}} \right) y \quad \left(\begin{array}{l} \text{対称性} \\ \text{ヘッセ性} \end{array} \right) \\
 &= \sum \underbrace{y' l_i}_{1 \times n} \underbrace{l_i' y}_{n \times 1} \quad \text{和の中に入れる} \\
 &\quad \underbrace{\hspace{1.5cm}}_{\text{先に計算}} \\
 &= \sum_{i=1}^p (l_i' y)^2
 \end{aligned}$$

意味：直交基底空間への射影行列の
各固有ベクトルとの内積をとり、その
総和。

L_2 ノルム



2.5.2

?

【 $(I - \pi_x)X = 0$ に (3) を代入するとわかる: 】

$$\begin{aligned} (I - \pi_x)X &= \left(\sum_{i=1}^K l_i l_i' \right) X = 0_{n \times n} \\ &= \sum_{i=1}^K \underbrace{l_i}_{n \times 1} \underbrace{l_i'}_{1 \times n} X_{n \times n} = 0_{n \times n} \end{aligned}$$

どうやら、 $l_i' X = 0_{1 \times n}$ が出たか + 正しいか。

l_i は $L(X)$ の直交補空間からとってきたベクトル。

$l_i' X = 0$ は当然な感じはする。

【 $l_i' y$ の期待値は、 $E(l_i' y) = 0$ である 】

$$\begin{aligned} E(l_i' y) &= E(\underbrace{l_i' X}_0 + l_i' \varepsilon) \\ &= E(l_i' \varepsilon) \\ &= l_i' E(\varepsilon) \\ &= 0 \end{aligned}$$

2.5.2 ?

$l_i'X = 0$ であることから、 $S(\hat{\theta})$ の各成分と
 値定可能関数全体 $X\hat{\theta}$ は無相関

$$\begin{aligned} \text{Cov}(X\hat{\theta}, y - X\hat{\theta}) &= \text{Cov}(\Pi_X y, (I - \Pi_X)y) \\ &= \Pi_X V(y) (I - \Pi_X)' \\ &= \sigma^2 \Pi_X (I - \Pi_X) \\ &= \mathbf{0}_{n \times n} \end{aligned}$$

$$\text{Cov}(X\hat{\theta}, y - X\hat{\theta}) = \text{Cov}(X\hat{\theta}, \sum l_i l_i' y)$$

$$\text{Cov}(X\hat{\theta}, S(\hat{\theta})) \text{ から出てくる!}$$

1.5.2

【(8).(9) 読者は: 九を確かめてほしい】

$$(10) \quad l_1 = \left(\frac{1}{\sqrt{2}}, -\frac{1}{\sqrt{2}}, 0 \right)$$

$$l_2 = \left(\frac{1}{\sqrt{6}}, \frac{1}{\sqrt{6}}, -\frac{2}{\sqrt{6}} \right) \quad \text{etc etc.}$$

$$S(\hat{\theta}) = (y - X\hat{\theta})' (y - X\hat{\theta})$$

$$= (y - \mathbb{1}\bar{y})' (y - \mathbb{1}\bar{y})$$

$$= y' (\mathbb{I} - \Pi_j)' (\mathbb{I} - \Pi_j) y$$

$$= \sum_{i=1}^{V_e} (l_i' y)^2$$

$$= \sum_{i=1}^2 (l_i' y)^2$$

$$= \left(\frac{1}{\sqrt{2}} y_1 - \frac{1}{\sqrt{2}} y_2 + 0 \right)^2 + \left(\frac{1}{\sqrt{6}} y_1 + \frac{1}{\sqrt{6}} y_2 - \frac{2}{\sqrt{6}} y_3 \right)^2$$

$$= \frac{1}{2} y_1^2 + \frac{1}{2} y_2^2 - y_1 y_2 + \frac{1}{6} y_1^2 + \frac{1}{6} y_2^2 + \frac{4}{6} y_3^2 \\ + \frac{2}{6} y_1 y_2 - \frac{4}{6} y_1 y_3 - \frac{4}{6} y_2 y_3$$

$$= \frac{4}{6} y_1^2 + \frac{4}{6} y_2^2 + \frac{4}{6} y_3^2 - \frac{4}{6} (y_1 y_2 + y_1 y_3 + y_2 y_3)$$

$$= \frac{4}{6} (y_1^2 + y_2^2 + y_3^2 - y_1 y_2 - y_1 y_3 - y_2 y_3)$$

$$(11) \quad l_1 = \left(-\frac{1}{\sqrt{2}} \quad , \quad 0 \quad , \quad \frac{1}{\sqrt{2}} \right)'$$

$$l_2 = \left(\frac{1}{\sqrt{6}} \quad , \quad -\frac{2}{\sqrt{6}} \quad , \quad \frac{1}{\sqrt{6}} \right)' \quad \text{etc.}$$

$$\begin{aligned} S(\hat{\theta}) &= \left(-\frac{1}{\sqrt{2}} y_1 + \frac{1}{\sqrt{2}} y_3 \right)^2 + \\ &\quad \left(\frac{1}{\sqrt{6}} y_1 - \frac{2}{\sqrt{6}} y_2 + \frac{1}{\sqrt{6}} y_3 \right)^2 \\ &= \frac{1}{2} y_1^2 + \frac{1}{2} y_3^2 - y_1 y_3 + \frac{1}{6} y_1^2 + \frac{4}{6} y_2^2 \\ &\quad + \frac{1}{6} y_3^2 - \frac{4}{6} y_1 y_2 + \frac{2}{6} y_1 y_3 - \frac{4}{6} y_2 y_3 \\ &= \frac{4}{6} (y_1^2 + y_2^2 + y_3^2 - y_1 y_2 - y_2 y_3 - y_1 y_3) \end{aligned}$$

(10) と同じ.

2.6.1



たとえば、仮説 (2.63) (2.66) はそれぞれ

$$(2.67) \quad H_0: E(y) = j\mu \quad \text{で表われる}$$



これを線形モデル

$$y = \begin{pmatrix} \vdots & \vdots & 0 & \vdots \\ \vdots & 0 & \vdots & \vdots \end{pmatrix} \begin{pmatrix} \mu \\ \alpha_1 \\ \alpha_2 \\ \alpha_3 \end{pmatrix} + \varepsilon \quad (*)$$

に $H_0: \alpha_1 = \alpha_2 = \dots = \alpha_n$ (2.63) μ

$H_0: \alpha_1 = \alpha_2 = \dots = \alpha_n = 0$ (2.66) を考えた.

これは (*) に代入すると、同じモデルに行き着くので、
始めから、

$$H_0: y = \begin{pmatrix} \vdots \\ \vdots \\ \vdots \end{pmatrix} (\mu) + \varepsilon$$

~~~~~ j

としよう.      としよう.



2.6.1



$L'y$  とは独立な不偏分散  $\hat{\sigma}^2$  と  $\sigma^2$  に代入れた

$$t = \frac{L'y}{\sqrt{L'L} \hat{\sigma}^2} \quad \text{は } t(\nu_e) \text{ に従う}$$



(1)  $L'y$  が  $\hat{\sigma}^2$  と独立なことを示す.

$L'y$  は推定可能関数であった。(2.68)

推定可能関数は  $X\theta$  の各要素およびその線形結合全体である.

一方、(2.61) より、 $\hat{\sigma}^2$  と  $X\theta$  は独立である。  
従って、 $\hat{\sigma}^2$  と  $L'y$  は独立

(2)  $t = \frac{L'y}{\sqrt{L'L} \hat{\sigma}^2}$  が  $t(\nu_e)$  に従う.

$$t = \frac{L'y}{\sqrt{L'L} \sigma^2} \cdot \frac{\sqrt{\sigma^2}}{\sqrt{\hat{\sigma}^2}} = Z \cdot \frac{1}{\sqrt{\frac{\hat{\sigma}^2}{\sigma^2}}}$$

$$\therefore \frac{\hat{\sigma}^2}{\sigma^2} = \frac{S(\hat{\theta})}{\nu_e} \cdot \frac{1}{\sigma^2} = \underbrace{\frac{S(\hat{\theta})}{\sigma^2}}_{\sim \chi(\nu_e)} \cdot \frac{1}{\nu_e}$$

$$\therefore \frac{Z}{\sqrt{\chi(\nu_e)/\nu_e}} \quad \text{の形になる.} \quad \sim \chi(\nu_e) \quad (\because 2.59)$$

2.6.1

## 仮説の自由度

2つ前のバージョンで.

$$X = \begin{pmatrix} 1 & 0 & 0 \\ \vdots & \vdots & \vdots \\ 0 & 0 & 0 \end{pmatrix} \in X_0 = \begin{pmatrix} 1 & 0 & 0 \\ \vdots & \vdots & \vdots \end{pmatrix} \text{ に対する話}$$

また. このとき.

$$p = \text{rank}(X_0) = 1$$

$$q = \text{rank}(X) = 3$$

$$S = 3 - 1 = 2 \text{ が 仮説の自由度}$$

$S_e$  および  $S_0$  を比較. このとき  $S_0 > S_e$  である

↓

何れも仮定は...の  
残差平方和

帰無仮説時の  
残差平方和.

直感的には.

$S_e$  より  $S_0$  の方が自由に動けるパラメータが  
少ないので. 残差が大きくなる

## 2.6.1

$$(2.79) \quad S_e = u_1^2 + \dots + u_{n-q}^2$$

$$(2.80) \quad S_o = \dots$$

(3), (4) より、

$$I - \Pi_X = \sum_{i=1}^{n-q} l_{xi}' l_{xi}$$

$$I - \Pi_{X_0} = \sum_{i=1}^{n-p} l_{x_0i}' l_{x_0i}$$

よって、

$$S_e = \sum_{i=1}^{n-q} (l_{xi}' y)^2 = u_1^2 + \dots + u_{n-q}^2$$

$$S_o = \sum_{i=1}^{n-p} (l_{x_0i}' y)^2 = u_1^2 + \dots + u_{n-q}^2 + \dots + u_{n-p}^2$$

ここで、 $l_{xi} = l_{x_0i}$  を使って、

本当??

$L(X_0)$  は  $L(X)$  に線形制約を加えたもの (図2.9

( $X \in \Theta$  のとるベクトル全体  $L(X)$  に対し、 $K\Theta = 0$  の制約)

より、 $L(X_0) \subset L(X)$

それぞれの直交補空間をとると

$$L(X_0)^\perp \supset L(X)^\perp$$

$$L(X)^\perp = \{ y \mid \forall x \in L(X), x \cdot y = 0 \}$$

$$\forall y \in L(X)^\perp \quad \exists x, x \in L(X),$$

$$\forall x_0 \in L(X_0) \quad \exists x, x \in L(X), x_0 \cdot y = 0$$

$$\text{よって } y \in L(X_0)^\perp$$

$I - \pi_x$  ,  $I - \pi_{x_0}$  はそれぞれ

$L(x)^\perp$  ,  $L(x_0)^\perp$  への射影子である。


射影子の固有ベクトルは (おそらく)  $L(x)^\perp$  ,  $L(x_0)^\perp$  の  
正規直交基底になっている。

$I - \pi_x$  の固有値 1 に対応する固有ベクトル  $\{l_{xi}\}_i$   
にいくつかのベクトルを加えることで、 $L(x_0)^\perp$  の  
基底を形成することができる。

よって、 $S_c$  と  $S_0$  で、一部共通の  $l_{xi} = l_{x_0i}$  と  
使っている。



図 2.9



【  $H_0$ のもとで、F分布に従う統計量 ... 】



$$\begin{aligned}
 F &= \left( \frac{S_0 - S_e}{g - p} \right) / \left( \frac{S_e}{n - g} \right) \\
 &= \left( \frac{\frac{S_0 - S_e}{\sigma^2}}{g} \right) / \left( \frac{\frac{S_e}{\sigma^2}}{n - g} \right) \\
 &= \left[ \frac{\chi^2(m)}{m} / \frac{\chi^2(n)}{n} \right] \text{ の形}
 \end{aligned}$$



(2.83)  $t = \frac{S_{xy} / S_{xx}}{\sqrt{\hat{\sigma}^2} / S_{xx}}$



2.64 同様.  $t = \frac{L' y}{\sqrt{L' L \hat{\sigma}^2}}$  となっているが、 $L$  は ... ?

そして  $L' y = l' \hat{\theta}$  としたとき、今回  $\beta_1$  は

具体的にわかっている。  $l = \begin{pmatrix} 0 \\ 1 \end{pmatrix}$  より  
 $L' y = (0 \ 1) \begin{pmatrix} \beta_0 \\ \beta_1 \end{pmatrix} = \hat{\beta}_1 = \frac{S_{xy}}{S_{xx}}$

また、 $L' y = l' (X' X)^{-1} X' y$  p50  
 $= (0 \ 1) \begin{pmatrix} n-1 & 0 \\ 0 & S_{xx}^{-1} \end{pmatrix} \begin{pmatrix} 1 & \bar{x}_1 - \bar{x} \\ & \vdots \end{pmatrix}' y$

$$= \begin{pmatrix} 0 & S_{xx}^{-1} \end{pmatrix} \begin{pmatrix} x_1 - \bar{x} & \dots & x_n - \bar{x} \end{pmatrix} y$$

$$= \underbrace{\frac{1}{S_{xx}} (x_1 - \bar{x} \dots x_n - \bar{x})}_{L'} y$$

$$\text{d.h. } L' L = \left( \frac{1}{S_{xx}} \right)^2 \cdot S_{xx} = \frac{1}{S_{xx}}$$

d.h.

$$t = \frac{S_{xy} / S_{xx}}{\sqrt{\hat{\sigma}^2 / S_{xx}}}$$

— A  $S_e$  ist (2.56) T. 2.5.6

$$S_0 = \sum y_i^2 - y.^2 / n \quad (\text{P 53 15.1 2.10})$$

$$S_e = \sum y_i^2 - y.^2 / n - S_{xy}^2 / S_{xx} \quad (2.56)$$

$$\text{d.h. } S_0 - S_e = \frac{S_{xy}^2}{S_{xx}}$$

q = 2, p = 1

$$\text{d.h. } E(y) = \underbrace{\begin{pmatrix} 1 & x_1 - \bar{x} \\ 1 & x_2 - \bar{x} \\ \vdots & \vdots \\ 1 & x_n - \bar{x} \end{pmatrix}}_{n \times 2} \begin{pmatrix} \beta_0 \\ \beta_1 \end{pmatrix} \quad \text{d.h. } E(y) = \underbrace{\begin{pmatrix} 1 \\ \vdots \\ 1 \end{pmatrix}}_{n \times 1} (\beta_0)$$

$$n = ar, \quad q = a, \quad p = 1 \quad \text{r.r.}$$

$n$  はデータ数分、 $a \times r$   
水準数      水準内観測数

$$q \text{ は } \text{rank}(X) = \text{rank} \begin{pmatrix} \vdots & \vdots & & \\ & 1 & & \\ & & \ddots & \\ & & & \vdots \end{pmatrix} = a$$

水準数

$$P. \text{t. } H_0 : E(y) = j\mu \quad (2.67) \quad \tau' \text{ の}$$

$$\text{rank}(j) = 1$$